

ĐẠI HỌC BÁCH KHOA HÀ NỘI

BÁO CÁO PROJECT

SPEECH EMOTION RECOGNITION

BẰNG CNN1D TRÊN RAVDESS

Xây dựng, huấn luyện và đánh giá hệ thống

Học phần:	Nhập môn Trí tuệ Nhân tạo
Giảng viên hướng dẫn:	TS. Ngô Văn Linh
Nhóm: 7	
1. Phạm Thị Bích Phương	202400069
2. Nguyễn Hải Yến Nhi	202400064
3. Nguyễn Thị Hải Linh	202416263

Hà Nội, 2026

Tóm tắt

Báo cáo này trình bày quá trình xây dựng hệ thống Nhận diện Cảm xúc qua Giọng nói (*Speech Emotion Recognition* - SER) sử dụng phần Audio Speech của tập dữ liệu RAVDESS. Thay vì sử dụng các trọng số có sẵn, nhóm đã tự thiết kế và huấn luyện mạng nơ-ron tích chập 1 chiều (CNN1D) bằng thư viện PyTorch. Để hệ thống trích xuất hiệu quả các đặc trưng âm thanh, mô hình sử dụng MFCC kết hợp với các thông số delta và delta-delta. Mục tiêu của hệ thống là phân loại audio đầu vào thành 8 trạng thái cảm xúc: **neutral**, **calm**, **happy**, **sad**, **angry**, **fearful**, **disgust** và **surprised**.

Thông qua các bước thử nghiệm và tinh chỉnh tham số, kết quả cho thấy việc chỉ bổ sung đặc trưng delta/delta-delta làm giảm độ chính xác nếu thiếu các kỹ thuật điều chuẩn (*regularization*) phù hợp. Tuy nhiên, ở phiên bản mô hình cuối cùng `cnn1d_mfcc_delta_ls005_adamw`, nhờ kết hợp thuật toán tối ưu AdamW, label smoothing (0.05), dropout (0.25) và tăng cường dữ liệu (*data augmentation*) nhẹ, mô hình đã cải thiện hiệu năng rõ rệt.

Đánh giá trên tập kiểm thử (test set) cho thấy hệ thống đạt độ chính xác (Accuracy) **91.67%** và chỉ số Macro F1 đạt **91.45%**. Mô hình dự đoán đúng 198/216 mẫu, trong đó nhóm cảm xúc **surprised** được nhận diện tốt nhất, còn **neutral** dễ bị nhầm lẫn với **calm** và **sad** nhất. Ngoài mã nguồn, project cũng đi kèm một ứng dụng Demo xây dựng bằng Streamlit để hỗ trợ kiểm thử trực quan.

Từ khóa: Speech Emotion Recognition, RAVDESS, CNN1D, MFCC, AdamW, label smoothing.

Mục lục

Tóm tắt	i
1 Giới thiệu	1
1.1 Bối cảnh và động lực	1
1.2 Mục tiêu và phạm vi của project	1
1.3 Kết quả đạt được	2
2 Tổng quan bài toán và dữ liệu	3
2.1 Phát biểu bài toán	3
2.2 Bộ dữ liệu RAVDESS	3
2.3 Quy ước tên file và nhãn	4
2.4 Chia train/validation/test	4
2.4.1 Class weights thực tế	5
2.4.2 Đặc điểm của chiến lược split	5
3 Kiến trúc hệ thống và cấu trúc mã nguồn	6
3.1 Kiến trúc tổng thể	6
3.2 Cấu trúc thư mục	6
3.3 Thiết kế cấu hình và experiment tracking	7
4 Tiền xử lý và biểu diễn đặc trưng	8
4.1 Load và chuẩn hóa audio	8
4.2 Data augmentation	8
4.3 MFCC, delta và delta-delta	8
4.4 Normalize per-sample	9
4.5 Minh họa feature	10
5 Mô hình CNN1D	11
5.1 Kiến trúc final model	11
5.2 Số lượng tham số	12
6 Huấn luyện và tuning	13

6.1	Training loop	13
6.2	Loss function	13
6.3	Optimizer, scheduler và early stopping	13
6.4	Thiết kế bốn experiment	14
6.5	Logic tuning và mức thay đổi	15
6.5.1	Baseline $\rightarrow$ delta ablation	15
6.5.2	Delta ablation $\rightarrow$ regularization ablation	15
6.5.3	Regularization ablation $\rightarrow$ final model	15
6.6	Biểu đồ so sánh experiment	16
7	Thực nghiệm và kết quả	17
7.1	Môi trường chạy	17
7.2	Kết quả tổng hợp	17
7.3	Classification report của final model	18
7.4	Confusion matrix	19
7.5	Phân tích lỗi theo lớp	19
7.5.1	Neutral	19
7.5.2	Calm	19
7.5.3	Happy và surprised	20
7.5.4	Sad	20
7.5.5	Angry và disgust	20
7.5.6	Fearful	20
7.5.7	Lớp tốt nhất và yếu nhất	20
7.6	Ý nghĩa của Macro F1 và Weighted F1	20
8	Inference và ứng dụng demo	21
8.1	Inference pipeline	21
8.2	Streamlit application	21
8.3	Phạm vi ứng dụng	22
9	Ưu điểm, hạn chế và hướng phát triển	23
9.1	Ưu điểm	23
9.2	Hạn chế	23
9.3	Hướng phát triển	23

10 Kết luận	25
A Lệnh chạy và tái lập	26
A.1 Cài đặt	26
A.2 Train final configuration	26
A.3 Evaluate và chạy demo	26
B Các tệp kết quả đi kèm	27

Danh sách hình vẽ

3.1	Pipeline xử lý chính của hệ thống.	6
4.1	Minh họa MFCC và Mel spectrogram của một audio sau xử lý. Các experiment chính sử dụng MFCC hoặc MFCC-delta.	10
5.1	Kiến trúc CNN1D được dùng trong các experiment chính.	11
6.1	So sánh accuracy, Macro F1 và Weighted F1 giữa bốn experiment.	16
7.1	Confusion matrix chuẩn hóa theo hàng của final checkpoint sau verified re-evaluation. Trục dọc là nhãn thật, trục ngang là nhãn dự đoán.	19

Danh sách bảng

2.1	Thông tin dữ liệu được sử dụng trong project	4
2.2	Mapping emotion code trong project	4
2.3	Phân bố từng lớp sau stratified split	5
2.4	Class weights theo phân bố train	5
3.1	Vai trò các thành phần chính của project	6
4.1	Cấu hình feature extraction	9
6.1	Hyperparameter huấn luyện của final model	14
6.2	So sánh cấu hình bốn experiment	14
7.1	Môi trường hiện tại	17
7.2	Kết quả các experiment trên test set	17
7.3	Classification report từ verified re-evaluation	18

Chương 1

Giới thiệu

1.1 Bối cảnh và động lực

Nhận diện cảm xúc qua giọng nói (Speech Emotion Recognition - SER) là bài toán phân tích và suy luận trạng thái tâm lý của người nói thông qua tín hiệu âm thanh. Khác với các hệ thống nhận dạng giọng nói truyền thống (Automatic Speech Recognition) vốn chỉ tập trung chuyển đổi lời nói thành văn bản, mục tiêu của SER là khai thác các "tín hiệu ẩn" phi ngôn ngữ như phổ tần, cao độ, năng lượng, tốc độ nói và sự biến thiên của chúng theo thời gian. Đây là một hướng tiếp cận quan trọng giúp máy tính giao tiếp tự nhiên và thấu hiểu con người hơn.

1.2 Mục tiêu và phạm vi của project

Mục tiêu cốt lõi của project là xây dựng thành công một hệ thống tự động phân loại cảm xúc từ file âm thanh. Thay vì sử dụng các trọng số có sẵn (*pretrained weights*), một mạng nơ-ron tích chập 1 chiều (CNN1D) được thiết kế và huấn luyện từ đầu nhằm giúp người thực hiện nắm vững nguyên lý hoạt động của từng thành phần trong mô hình.

Để hiện thực hóa mục tiêu này, project tập trung giải quyết các nhiệm vụ cụ thể:

1. Xây dựng một luồng xử lý (*pipeline*) hoàn chỉnh: từ bước làm sạch âm thanh, trích xuất đặc trưng (MFCC kết hợp delta/delta-delta) cho đến đầu ra dự đoán.
2. Thực nghiệm và đánh giá ảnh hưởng của các siêu tham số (thuật toán tối ưu, *dropout*, *label smoothing*) đến hiệu năng mô hình.
3. Trình bày các kết quả đánh giá một cách minh bạch thông qua các chỉ số như Accuracy, F1-Score và Ma trận nhầm lẫn (Confusion Matrix).
4. Phát triển một ứng dụng trực quan (Demo bằng Streamlit) cho phép người dùng tải file hoặc ghi âm trực tiếp để kiểm thử mô hình.

Về mặt kỹ thuật, mục tiêu ban đầu được đặt ra là đạt độ chính xác (Test Accuracy) tối thiểu 65% và chỉ số Macro F1 khoảng 0.60. Tuy nhiên, kết quả thực tế của phiên bản mô hình cuối cùng đã vượt xa kỳ vọng, đạt Accuracy **91.67%** và Macro F1 **91.45%**.

1.3 Kết quả đạt được

Kết thúc quá trình thực hiện, một *pipeline end-to-end* ổn định từ khâu tiền xử lý dữ liệu thô đến khi ra quyết định phân loại đã được hoàn thiện. Toàn bộ các thử nghiệm đều được quản lý có hệ thống, lưu trữ *checkpoint* và cấu hình rõ ràng để dễ dàng đối chiếu. Đặc biệt, project đã thiết kế thành công bốn kịch bản thử nghiệm cơ bản để kiểm chứng và đánh giá độc lập hiệu quả của từng kỹ thuật được áp dụng. Cuối cùng, project cũng đi kèm một ứng dụng Demo xây dựng bằng Streamlit để hỗ trợ hỗ trợ quá trình dự đoán một cách trực quan, sát với thực tế ứng dụng.

Chương 2

Tổng quan bài toán và dữ liệu

2.1 Phát biểu bài toán

Với mỗi tín hiệu audio đầu vào x , hệ thống dự đoán cảm xúc thuộc một trong 8 lớp:

$$\mathcal{Y} = \{\text{neutral, calm, happy, sad, angry, fearful, disgust, surprised}\}.$$

Mô hình tạo ra một điểm số cho mỗi lớp cảm xúc. Lớp có điểm số lớn nhất được chọn làm kết quả dự đoán:

$$\hat{y} = \arg \max_k z_k.$$

Trong quá trình huấn luyện, các điểm số này được dùng trực tiếp để tính Cross-Entropy Loss. Khi dự đoán, hàm softmax chuyển chúng thành xác suất của từng lớp:

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^8 e^{z_j}}.$$

2.2 Bộ dữ liệu RAVDESS

RAVDESS là bộ dữ liệu đa phương thức gồm 24 diễn viên chuyên nghiệp, 12 nam và 12 nữ. Phần Audio Speech có 1.440 file, tương ứng 60 trial trên mỗi actor. Các file audio-only gốc có định dạng WAV 16-bit, 48 kHz; project resample về 22.050 Hz khi đọc dữ liệu [2].

Bảng 2.1: Thông tin dữ liệu được sử dụng trong project

Thuộc tính	Giá trị
Dataset	RAVDESS Audio Speech
Số file	1.440
Số actor	24
Số lớp	8
Định dạng input chính	WAV
Sample rate sau khi load	22.050 Hz
Độ dài chuẩn hóa	3 giây

2.3 Quy ước tên file và nhãn

Tên file RAVDESS gồm bảy trường số: modality, vocal channel, emotion, emotional intensity, statement, repetition và actor. Project lấy trường thứ ba làm emotion code. Mapping được dùng trong project được trình bày ở Bảng 2.2.

Bảng 2.2: Mapping emotion code trong project

Code	Nhãn	Code	Nhãn
01	neutral	05	angry
02	calm	06	fearful
03	happy	07	disgust
04	sad	08	surprised

2.4 Chia train/validation/test

Hàm `build_dataset()` sử dụng hai lần `train_test_split` với `stratify=labels`, random seed 42 và tỉ lệ 70/15/15.

Bảng 2.3: Phân bố từng lớp sau stratified split

Emotion	Train	Validation	Test	Tổng
neutral	67	15	14	96
calm	135	29	28	192
happy	135	28	29	192
sad	134	29	29	192
angry	134	29	29	192
fearful	134	29	29	192
disgust	135	28	29	192
surprised	134	29	29	192
Tổng	1008	216	216	1440

Lớp `neutral` chỉ có 96 mẫu, bằng một nửa mỗi lớp còn lại. Đây là lý do hợp lý để project dùng class-weighted Cross-Entropy Loss và báo cáo Macro F1 bên cạnh accuracy.

2.4.1 Class weights thực tế

Trọng số lớp được tính theo:

$$w_c = \frac{N}{K n_c},$$

sau đó chuẩn hóa để trung bình các trọng số bằng 1. Từ phân bố train ở Bảng 2.3, trọng số thu được xấp xỉ như Bảng 2.4.

Bảng 2.4: Class weights tính lại theo đúng hàm `compute_class_weights()`

Lớp	Weight	Lớp	Weight
neutral	1.7822	angry	0.8911
calm	0.8845	fearful	0.8911
happy	0.8845	disgust	0.8845
sad	0.8911	surprised	0.8911

2.4.2 Đặc điểm của chiến lược split


Split được stratify theo nhãn, nhờ đó phân bố tám lớp được duy trì ổn định giữa train, validation và test. Các split được tạo theo file; vì vậy, đánh giá theo actor độc lập là một hướng mở rộng phù hợp để kiểm tra khả năng tổng quát hóa sang người nói mới.

Chương 3

Kiến trúc hệ thống và cấu trúc mã nguồn

3.1 Kiến trúc tổng thể

Pipeline chính của hệ thống được minh họa ở Hình 3.1.



Hình 3.1: Pipeline xử lý chính của hệ thống.

3.2 Cấu trúc thư mục

Bảng 3.1: Vai trò các thành phần chính của project

Thành phần	Vai trò
src/config.py	Đường dẫn, label mapping, feature config, hyperparameter và biến môi trường.
src/dataset.py	Parse filename, tạo Dataset, stratified split train/validation/test.
src/features.py	Load, trim, fix length, augmentation, MFCC, delta/delta-delta, Mel spectrogram.
src/model.py	Kiến trúc CNN1D, biến thể mở rộng và model registry.
src/train.py	Training loop, class weights, loss, optimizer, scheduler, early stopping và checkpoint.
src/evaluate.py	Test metrics, classification report và confusion matrix.
src/inference.py	Load checkpoint, tái tạo model và predict file audio mới.

Thành phần	Vai trò
<code>src/utils.py</code>	Random seed, device selection và ghi experiment CSV.
<code>app/streamlit_app.py</code>	Giao diện upload/record audio và hiển thị probability.
<code>app/recorder.py</code>	Thu âm microphone và lưu PCM WAV.
<code>experiments/results.csv</code>	Bảng tổng hợp kết quả experiment.
<code>checkpoints/<run_name>/</code>	Lưu best/last checkpoint, config và metrics theo run.
<code>report/figures/</code>	Hình ảnh sử dụng trong báo cáo.

3.3 Thiết kế cấu hình và experiment tracking

Các hyperparameter được khai báo trong `src/config.py` và có thể ghi đè qua biến môi trường như `SER_RUN_NAME`, `SER_FEATURE_TYPE`, `SER_OPTIMIZER`, `SER_LABEL_SMOOTHING`, `SER_DROPOUT`, `SER_LEARNING_RATE` và `SER_RANDOM_SEED`. Mỗi run lưu config và metrics riêng, đồng thời append kết quả vào `experiments/results.csv`.

Ưu điểm:

- Kết quả có thể truy vết về cấu hình cụ thể;
- Inference đọc lại model name, feature type và input channels từ checkpoint, giảm nguy cơ mismatch giữa training và prediction.

Chương 4

Tiền xử lý và biểu diễn đặc trưng

4.1 Load và chuẩn hóa audio

Audio được load bằng Librosa với sample rate 22.050 Hz. Sau đó, `librosa.effects.trim(..., top_db=20)` được dùng để cắt khoảng lặng đầu và cuối. Tín hiệu được pad hoặc truncate về đúng 3 giây:

$$L = 22050 \times 3 = 66150 \text{ samples.}$$

Việc cố định độ dài đảm bảo các sample có cùng số time frame sau feature extraction và có thể ghép batch trực tiếp.

4.2 Data augmentation

Nhằm hạn chế tình trạng overfitting, augmentation chỉ được kích hoạt cho tập train. Hệ thống sử dụng ba phép biến đổi chính:

- **Time stretch:** Điều chỉnh tốc độ nói (nh nhanh hoặc chậm hơn).
- **Pitch shift:** Can thiệp làm thay đổi cao độ của giọng nói.
- **Gaussian noise:** Chèn thêm các dải nhiễu trắng với biên độ nhỏ để mô phỏng môi trường thực tế.

Validation và test không sử dụng augmentation. Điều này giúp các metric đánh giá phản ánh dữ liệu gốc sau tiền xử lý chuẩn.

4.3 MFCC, delta và delta-delta

Cấu hình MFCC chính:

Bảng 4.1: Cấu hình feature extraction

Tham số	Giá trị
Sample rate	22.050 Hz
Duration	3.0 s
n_mfcc	40
n_fft	2048
hop_length	512
MFCC channels	40
MFCC-delta channels	120

Nếu `feature_type=mfcc`, input có 40 channels. Nếu `feature_type=mfcc_delta`, code ghép:

$$\mathbf{X} = \text{concat}(\text{MFCC}, \Delta\text{MFCC}, \Delta^2\text{MFCC})$$

thành 120 channels. Delta và delta-delta bổ sung thông tin thay đổi theo thời gian, phù hợp với đặc trưng động của giọng nói.


4.4 Normalize per-sample

Feature được chuẩn hóa theo toàn bộ ma trận của mỗi sample:

$$\mathbf{X}' = \frac{\mathbf{X} - \mu_{\mathbf{X}}}{\sigma_{\mathbf{X}} + 10^{-8}}.$$

Mục đích là giảm chênh lệch scale giữa các file và giúp tối ưu ổn định hơn.

4.5 Minh họa feature



Hình 4.1: Minh họa MFCC và Mel spectrogram của một audio sau xử lý. Các experiment chính sử dụng MFCC hoặc MFCC-delta.

Trong Hình 4.1, vùng gần như đồng nhất sau phân tín hiệu chính phản ánh đoạn padding để đưa audio về độ dài cố định. MFCC là đặc trưng được sử dụng trong pipeline thực nghiệm, còn Mel spectrogram được trình bày để minh họa một biểu diễn phổ thay thế.

Chương 5


Mô hình CNN1D

5.1 Kiến trúc final model

CNN1D nhận input dạng:

$$(B, C, T),$$

trong đó B là batch size, $C = 40$ hoặc 120 và T là số time frame. Final model dùng $C = 120$.



Hình 5.1: Kiến trúc CNN1D được dùng trong các experiment chính.

Adaptive average pooling làm classifier độc lập với dao động nhỏ của số frame. Forward trả về logits, không áp dụng softmax trong model.

5.2 Số lượng tham số

Tính trực tiếp từ kiến trúc trong `src/model.py`, final CNN1D với 120 input channels và 8 lớp có khoảng:

278,472

tham số trainable, bao gồm convolution, batch normalization và fully-connected layers. Đây là mô hình tương đối nhẹ, phù hợp với dataset nhỏ và môi trường CPU.

Chương 6

Huấn luyện và tuning

6.1 Training loop

Training pipeline trong `src/train.py` gồm:

1. Đặt random seed và chọn device;
2. Tạo train/validation/test dataset và DataLoader;
3. Tạo model theo config;
4. Tính class weights từ train labels;
5. Tối ưu weighted Cross-Entropy Loss có label smoothing;
6. Đánh giá validation sau mỗi epoch;
7. Cập nhật ReduceLROnPlateau theo validation loss;
8. Lưu `last_model.pt` mỗi epoch và `best_model.pt` khi metric cải thiện;
9. Early stopping sau 7 epoch không cải thiện;
10. Load best checkpoint và đánh giá trên test set.

6.2 Loss function

Final model dùng weighted Cross-Entropy với label smoothing $\varepsilon = 0.05$. Với phân phối target đã làm mượt q_k và probability p_k , loss có dạng:

$$\mathcal{L} = -w_y \sum_{k=1}^K q_k \log p_k.$$

Class weight xử lý mất cân bằng của lớp neutral; label smoothing giảm mức quá tự tin vào nhãn one-hot.

6.3 Optimizer, scheduler và early stopping

Final config:

Bảng 6.1: Hyperparameter huấn luyện của final model

Hyperparameter	Giá trị
Model	CNN1D
Feature	MFCC + delta + delta-delta
Input channels	120
Batch size	32
Learning rate	0.001
Weight decay	0.0001
Optimizer	AdamW
Dropout	0.25
Label smoothing	0.05
Max epochs	50
Early-stop patience	7
Scheduler	ReduceLROnPlateau
Scheduler patience/factor	3 / 0.5
Best metric	minimum validation loss

6.4 Thiết kế bốn experiment

Bảng 6.2 đối chiếu chính xác các config được cung cấp.

Ký hiệu các run trong bảng:

- E1: cnn1d_mfcc_baseline_organic;
- E2: cnn1d_mfcc_delta_fix1_organic;
- E3: cnn1d_mfcc_delta_ls005_do025_adam;
- E4: cnn1d_mfcc_delta_ls005_adamw.

Bảng 6.2: So sánh cấu hình bốn experiment

Run	Feature	Ch.	Opt.	LS	DO	Stretch	Pitch	Noise
E1	MFCC	40	Adam	0.00	0.30	0.90–1.10	± 2	0.005
E2	MFCC+ Δ + Δ^2	120	Adam	0.00	0.30	0.90–1.10	± 2	0.005
E3	MFCC+ Δ + Δ^2	120	Adam	0.05	0.25	0.90–1.10	± 2	0.005
E4	MFCC+ Δ + Δ^2	120	AdamW	0.05	0.25	0.95–1.05	± 1	0.003

6.5 Logic tuning và mức thay đổi

6.5.1 Baseline → delta ablation

Hai run đầu chỉ khác feature type và số input channels. Đây là ablation tương đối sạch. Khi thêm delta/delta-delta:

- Accuracy giảm 8.80 điểm phần trăm;
- Macro F1 giảm 9.59 điểm;
- Weighted F1 giảm 8.96 điểm.

Kết quả cho thấy thông tin động học không tự động cải thiện model. Input tăng từ 40 lên 120 channels làm bài toán tối ưu phức tạp hơn.

6.5.2 Delta ablation → regularization ablation

Hai run này giữ Adam và augmentation giống nhau, nhưng thay đổi label smoothing từ 0 lên 0.05 và dropout từ 0.30 xuống 0.25. Kết quả:

- Accuracy tăng 5.56 điểm;
- Macro F1 tăng 6.03 điểm;
- Weighted F1 tăng 5.24 điểm.

Điều này là bằng chứng rằng regularization configuration mới giúp phục hồi một phần hiệu năng của MFCC-delta, dù vẫn thấp hơn baseline MFCC.

6.5.3 Regularization ablation → final model


Final run đổi Adam sang AdamW và đồng thời giảm cường độ augmentation. Kết quả tăng:

- Accuracy: +21.76 điểm;
- Macro F1: +22.50 điểm;
- Weighted F1: +22.33 điểm.

Phân tích kỹ thuật

Final run đồng thời sử dụng AdamW và augmentation nhẹ hơn. Vì vậy, mức cải thiện được diễn giải là hiệu quả của **cấu hình tổng thể**: AdamW + augmentation nhẹ trên nền MFCC-delta, label smoothing 0.05 và dropout 0.25.

6.6 Biểu đồ so sánh experiment



Hình 6.1: So sánh accuracy, Macro F1 và Weighted F1 giữa bốn experiment.

Final model cao hơn baseline 18.52 điểm accuracy, 18.94 điểm Macro F1 và 18.61 điểm Weighted F1.

Chương 7

Thực nghiệm và kết quả

7.1 Môi trường chạy

Bảng 7.1: Môi trường hiện tại

Thành phần	Giá trị
OS	Windows 11 (10.0.26200)
Python trong uv	3.13.13
PyTorch	2.12.0+cpu
CUDA	Không khả dụng
Device	CPU

7.2 Kết quả tổng hợp

Bảng 7.2: Kết quả các experiment trên test set

Run	Feature	Loss	Acc.	Macro F1	Weighted F1
E1	MFCC	0.8344	0.7315	0.7251	0.7312
E2	MFCC+ Δ + Δ^2	0.9725	0.6435	0.6292	0.6416
E3	MFCC+ Δ + Δ^2	1.0244	0.6991	0.6895	0.6940
E4	MFCC+ Δ + Δ^2	0.5792	0.9167	0.9145	0.9173


Final checkpoint phân loại đúng 198/216 mẫu và sai 18 mẫu.

7.3 Classification report của final model

Bảng 7.3: Classification report từ verified re-evaluation

Emotion	Precision	Recall	F1-score	Support
neutral	0.7778	1.0000	0.8750	14
calm	1.0000	0.8214	0.9020	28
happy	0.9286	0.8966	0.9123	29
sad	0.9000	0.9310	0.9153	29
angry	0.9286	0.8966	0.9123	29
fearful	0.8286	1.0000	0.9062	29
disgust	0.9630	0.8966	0.9286	29
surprised	1.0000	0.9310	0.9643	29
Macro average	0.9158	0.9216	0.9145	216
Weighted average	0.9250	0.9167	0.9173	216

7.4 Confusion matrix



Hình 7.1: Confusion matrix chuẩn hóa theo hàng của final checkpoint sau verified re-evaluation. Trục dọc là nhãn thật, trục ngang là nhãn dự đoán.

7.5 Phân tích lỗi theo lớp

7.5.1 Neutral

Cả 14 mẫu neutral đều được nhận diện đúng, nên recall bằng 1.00. Tuy nhiên, precision chỉ 0.7778 vì ba mẫu calm và một mẫu sad bị dự đoán thành neutral. Do đó, neutral có F1 thấp nhất dù không bỏ sót mẫu neutral nào.

7.5.2 Calm

Model dự đoán calm rất thận trọng: tất cả prediction calm đều đúng, nên precision bằng 1.00. Ngược lại, recall chỉ 0.8214 vì 5/28 mẫu calm bị bỏ sót: ba mẫu chuyển sang neutral và hai mẫu chuyển sang sad.

7.5.3 Happy và surprised

Happy đúng 26/29; ba mẫu bị dự đoán thành fearful. Surprised đúng 27/29; hai mẫu bị dự đoán thành happy. Đây là một cặp có quan hệ nhầm lẫn một chiều trong test split: surprised $\rightarrow$ happy xuất hiện, nhưng happy không chuyển sang surprised trong confusion matrix này.

7.5.4 Sad

Sad đúng 27/29. Một mẫu bị dự đoán thành neutral và một mẫu thành fearful. Precision bằng 0.90 do model nhận thêm hai calm và một disgust vào lớp sad.

7.5.5 Angry và disgust

Angry đúng 26/29: hai mẫu sang fearful, một mẫu sang disgust. Disgust đúng 26/29: hai mẫu sang angry, một mẫu sang sad. Đây là cặp có nhầm lẫn hai chiều rõ trong test split.

7.5.6 Fearful

Fearful có recall 1.00 vì toàn bộ 29 mẫu thật được nhận diện đúng. Precision đạt 0.8286 do lớp này nhận thêm sáu false positive: ba happy, một sad và hai angry. Các lỗi tập trung này cho thấy model có xu hướng gán một số mẫu cảm xúc cường độ cao vào lớp fearful.

7.5.7 Lớp tốt nhất và yếu nhất

- F1 cao nhất: **surprised**, 0.9643.
- F1 thấp nhất: **neutral**, 0.8750.
- Recall cao nhất: **neutral** và **fearful**, đều 1.00.
- Precision cao nhất: **calm** và **surprised**, đều 1.00.

7.6 Ý nghĩa của Macro F1 và Weighted F1

Macro F1 0.9145 và Weighted F1 0.9173 gần nhau, cho thấy hiệu năng không chỉ đến từ các lớp có nhiều mẫu. Tuy nhiên, neutral vẫn có support nhỏ, nên classification report và confusion matrix cần được đọc cùng các metric trung bình.

Chương 8

Inference và ứng dụng demo

8.1 Inference pipeline

`src/inference.py` thực hiện:

1. Load checkpoint;
2. Đọc config đã lưu trong checkpoint;
3. Tạo đúng model class và số input channels;
4. Load `model_state_dict`;
5. Xử lý audio với `use_augment=False`;
6. Forward qua model và áp dụng softmax;
7. Trả về nhãn, index, confidence và toàn bộ probability vector.

Việc đọc `feature_type` và `n_features` từ checkpoint giúp tránh lỗi dùng MFCC 40 channels để inference cho model đã train với MFCC-delta 120 channels.

8.2 Streamlit application

Demo dùng final run `cnn1d_mfcc_delta_ls005_adam` và hỗ trợ:

- Upload WAV, MP3, FLAC hoặc OGG;
- Ghi âm từ microphone;
- Phát lại audio;
- Hiển thị emotion label và confidence;
- Hiển thị biểu đồ probability của tám lớp;
- Hiển thị model summary và test metrics.

8.3 Phạm vi ứng dụng

Demo hoạt động theo cơ chế record-then-predict, phù hợp với việc thử nghiệm từng đoạn audio ngắn. Vì model được huấn luyện trên RAVDESS, kết quả có độ tin cậy cao nhất khi input có đặc điểm âm thanh gần với dữ liệu huấn luyện.

Chương 9

Ưu điểm, hạn chế và hướng phát triển

9.1 Ưu điểm

1. Pipeline đầy đủ từ dữ liệu đến demo.
2. Code chia module rõ ràng: config, dataset, feature, model, train, evaluate, inference.
3. Có config và experiment tracking theo run.
4. Dùng stratified split, class weights, Macro F1 và confusion matrix.
5. Có các ablation trung gian, không chỉ báo cáo final model.
6. Mô hình nhẹ, có thể chạy trong môi trường CPU.

9.2 Hạn chế

1. RAVDESS là dữ liệu cảm xúc diễn xuất trong môi trường thu có kiểm soát, nên phân phối audio thực tế có thể khác dữ liệu huấn luyện.
2. Split hiện tại được stratify theo nhân và chưa tách hoàn toàn theo actor; đánh giá theo người nói độc lập sẽ kiểm tra khả năng tổng quát hóa nghiêm ngặt hơn.
3. Hệ thống xử lý đoạn audio có độ dài cố định và demo theo cơ chế record-then-predict, phù hợp với phạm vi của project hiện tại.

9.3 Hướng phát triển

1. Chia dữ liệu theo actor để đánh giá khả năng nhận diện trên người nói mới.
2. Bổ sung dữ liệu tự nhiên hoặc các bộ dữ liệu SER khác để đánh giá khả năng thích nghi giữa các miền dữ liệu.
3. Thực hiện ablation riêng cho AdamW và augmentation strength nhằm định lượng đóng góp của từng thành phần.

4. Mở rộng demo theo hướng xử lý luồng audio liên tục và bổ sung hiển thị waveform/spectrogram theo thời gian thực.
5. So sánh CNN1D với các mô hình biểu diễn âm thanh hiện đại như wav2vec2, HuBERT hoặc WavLM.

Chương 10

Kết luận

Project đã xây dựng thành công một hệ thống Speech Emotion Recognition hoàn chỉnh trên RAVDESS. Pipeline sử dụng audio 3 giây, MFCC/MFCC-delta, CNN1D, weighted Cross-Entropy, augmentation, checkpointing, evaluation và Streamlit inference.

Verified re-evaluation của final checkpoint `cnn1d_mfcc_delta_ls005_adamw` đạt accuracy 91.67%, Macro F1 91.45% và Weighted F1 91.73%. Confusion matrix cho thấy 198/216 mẫu được phân loại đúng. Mô hình nhận diện rất tốt neutral và fearful theo recall, nhưng precision của hai lớp này thấp hơn do nhận false positive; surprised là lớp có F1 cao nhất.

Phân tích tuning cho thấy việc thêm delta/delta-delta cần đi kèm regularization và chiến lược tối ưu phù hợp. Final configuration gồm MFCC-delta, label smoothing 0.05, dropout 0.25, AdamW và augmentation nhẹ đạt bước cải thiện lớn nhất và cho hiệu năng tốt nhất trong các thử nghiệm.

Hệ thống có cấu trúc module rõ ràng, quy trình thực nghiệm có thể tái lập và kết quả phân loại cao trên RAVDESS. Các hướng mở rộng ưu tiên là đánh giá theo actor độc lập, bổ sung dữ liệu tự nhiên và mở rộng khả năng xử lý audio trong ứng dụng.

Chương A

Lệnh chạy và tải lập

A.1 Cài đặt

```
uv sync
```

A.2 Train final configuration

```
SER_RUN_NAME=cnn1d_mfcc_delta_ls005_adamw \  
SER_FEATURE_TYPE=mfcc_delta \  
SER_OPTIMIZER=adamw \  
SER_LABEL_SMOOTHING=0.05 \  
SER_DROPOUT=0.25 \  
SER_AUG_TIME_STRETCH_MIN=0.95 \  
SER_AUG_TIME_STRETCH_MAX=1.05 \  
SER_AUG_PITCH_SHIFT_MIN=-1.0 \  
SER_AUG_PITCH_SHIFT_MAX=1.0 \  
SER_AUG_NOISE_STD=0.003 \  
uv run python -m src.train
```

A.3 Evaluate và chạy demo

```
uv run python -m src.evaluate  
uv run streamlit run app/streamlit_app.py
```

Chương B

Các tệp kết quả đi kèm

Bộ báo cáo kèm theo các tệp:

- `artifacts/dataset_split.csv`;
- `artifacts/results.csv`;
- `artifacts/final_evaluation.txt`;
- `artifacts/environment.txt`;
- bốn file config JSON;
- ba hình trong thư mục `figures/`.

Tài liệu tham khảo

- [1] S. R. Livingstone and F. A. Russo, “The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English,” *PLOS ONE*, vol. 13, no. 5, e0196391, 2018.
- [2] S. R. Livingstone and F. A. Russo, *The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS)*, Zenodo, Version 1.0.0, 2018. DOI: 10.5281/zenodo.1188976.
- [3] PyTorch Contributors, *PyTorch Documentation*, <https://pytorch.org/docs/stable/>.
- [4] Librosa Development Team, *Librosa Documentation*, <https://librosa.org/doc/latest/>.
- [5] Scikit-learn Developers, *Scikit-learn Documentation*, <https://scikit-learn.org/stable/>.