

Speech Emotion Recognition bằng CNN1D trên RAVDESS

Xây dựng, tuning và đánh giá hệ thống nhận diện cảm xúc giọng nói

Phạm Thị Bích Phương Nguyễn Hải Yến Nhi Nguyễn Thị Hải Linh

Đại học Bách khoa Hà Nội

Ngày 19 tháng 6 năm 2026

Nội dung trình bày

- ➊ Motivation và phát biểu bài toán
- ➋ Dataset RAVDESS
- ➌ Pipeline xử lý audio
- ➍ Feature extraction
- ➎ Kiến trúc CNN1D
- ➏ Training pipeline
- ➐ Tuning model
- ➑ Kết quả thực nghiệm
- ➒ Phân tích confusion matrix
- ➓ Kết luận và hướng phát triển

Bối cảnh

Giọng nói không chỉ chứa nội dung ngôn ngữ mà còn mang thông tin về cảm xúc, cường độ, nhịp điệu và trạng thái của người nói.

- Speech Emotion Recognition hỗ trợ tương tác người–máy, trợ lý ảo, chăm sóc khách hàng và phân tích trải nghiệm người dùng.
- Bài toán khó vì cảm xúc có thể biểu hiện tinh tế, phụ thuộc người nói và điều kiện ghi âm.
- Mục tiêu: xây dựng pipeline nhận diện cảm xúc từ audio, có huấn luyện, tuning, đánh giá và demo.

Bài toán phân loại đa lớp

Với mỗi tín hiệu audio đầu vào x , hệ thống dự đoán cảm xúc thuộc một trong 8 lớp của RAVDESS.

$$\mathcal{Y} = \{\text{neutral, calm, happy, sad, angry, fearful, disgust, surprised}\}.$$

Input

- Audio waveform
- Sample rate chuẩn hóa
- Độ dài cố định 3 giây

Mô hình tạo ra một điểm số cho mỗi lớp; lớp có điểm số lớn nhất là dự đoán cuối cùng.

Output

- Nhãn cảm xúc
- Confidence score
- Xác suất trên 8 lớp

Dataset: RAVDESS Audio Speech

Thông tin chính

- 1.440 file WAV
- 24 diễn viên
- 8 lớp cảm xúc
- Tên file mã hóa emotion code

Code	Emotion
01	neutral
02	calm
03	happy
04	sad
05	angry
06	fearful
07	disgust
08	surprised

Data split


Stratified split theo nhãn với tỉ lệ train/validation/test = **70/15/15**, random seed = **42**.

Phân bố dữ liệu sau khi split

Emotion	Train	Validation	Test
neutral	67	15	14
calm	135	29	28
happy	135	28	29
sad	134	29	29
angry	134	29	29
fearful	134	29	29
disgust	135	28	29
surprised	134	29	29
Tổng	1008	216	216


- Phân bố giữa các split tương đối ổn định nhờ stratified split.
- Lớp `neutral` có ít mẫu hơn, nên đánh giá dùng thêm Macro F1 và loss có class weight.

Pipeline xử lý dữ liệu



- Audio được đưa về cùng sample rate và độ dài cố định.
- Feature chính: MFCC hoặc MFCC + delta + delta-delta.
- Softmax chỉ dùng ở inference để hiển thị xác suất từng lớp.

Feature extraction



Hình: Minh họa MFCC và Mel spectrogram của một audio sau tiền xử lý.

Feature được dùng trong thực nghiệm

Feature	Thành phần	Shape
MFCC	40 MFCC	$(40, T)$
MFCC- Δ	$\text{MFCC} + \Delta + \Delta^2$	$(120, T)$


Ý nghĩa

- MFCC: thông tin phổ âm.
- Delta: xu hướng thay đổi theo thời gian.
- Delta-delta: thay đổi bậc hai của feature.

$$x' = \frac{x - \mu}{\sigma + 10^{-8}}$$

Normalize per-sample giúp ổn định scale feature trước khi đưa vào CNN1D.

CNN1D architecture



- CNN1D học các local temporal patterns trên chuỗi feature âm thanh.
- Khi train, các điểm số đầu ra được đưa trực tiếp vào Cross-Entropy Loss.

Training pipeline

Training setup

- Epochs: 50
- Batch size: 32
- Learning rate: 0.001
- Weight decay: 0.0001
- Early stopping: patience = 7

Optimization

- Loss: weighted Cross-Entropy
- Label smoothing: 0 hoặc 0.05
- Optimizer: Adam / AdamW
- Scheduler: ReduceLROnPlateau

Class weight

$$w_c = \frac{N}{K \cdot n_c}$$

Class weight giúp giảm bias khi số mẫu giữa các lớp không hoàn toàn cân bằng.

Chiến lược tuning model


Tuning theo hướng ablation

Thay đổi từng nhóm cấu hình để quan sát ảnh hưởng của feature, regularization và optimizer lên hiệu năng.

Experiment	Feature	Regularization	Optimizer
Baseline	MFCC	Dropout 0.30, LS 0.00	Adam
Delta ablation	MFCC- Δ	Dropout 0.30, LS 0.00	Adam
Regularization	MFCC- Δ	Dropout 0.25, LS 0.05	Adam
Final model	MFCC- Δ	Dropout 0.25, LS 0.05	AdamW

- Final model đồng thời dùng AdamW và augmentation nhẹ hơn.
- Vì vậy, kết quả tốt nhất được xem là hiệu quả của toàn bộ configuration cuối.

Kết quả tuning theo experiment



Hình: So sánh Accuracy, Macro F1 và Weighted F1 trên test set.

Bảng kết quả thực nghiệm

Run	Loss	Acc	Macro F1	Weighted F1
MFCC + Adam	0.8344	0.7315	0.7251	0.7312
MFCC- Δ + Adam	0.9725	0.6435	0.6292	0.6416
MFCC- Δ + LS + DO + Adam	1.0244	0.6991	0.6895	0.6940
MFCC- Δ + LS + DO + AdamW	0.5792	0.9167	0.9145	0.9173

Final configuration

cnn1d_mfcc_delta_ls005_adamw: CNN1D + MFCC- Δ + label smoothing 0.05 + dropout 0.25 + AdamW + augmentation nhẹ.


Final model: kết quả theo từng lớp

Emotion	Precision	Recall	F1-score	Support
neutral	0.7778	1.0000	0.8750	14
calm	1.0000	0.8214	0.9020	28
happy	0.9286	0.8966	0.9123	29
sad	0.9000	0.9310	0.9153	29
angry	0.9286	0.8966	0.9123	29
fearful	0.8286	1.0000	0.9062	29
disgust	0.9630	0.8966	0.9286	29
surprised	1.0000	0.9310	0.9643	29

Verified re-evaluation

Accuracy = **91.67%**, Macro F1 = **91.45%**, Weighted F1 = **91.73%**.

Confusion matrix



Nhận xét chính

- neutral: recall 1.00, precision thấp hơn do false positive.
- calm: nhầm sang neutral và sad.
- happy và surprised có overlap.
- fearful: recall 1.00, nhận thêm mẫu từ lớp khác.

Inference flow

- 1 Load checkpoint final
- 2 Đọc config đã lưu
- 3 Trích xuất đúng feature type
- 4 Forward qua CNN1D
- 5 Softmax để lấy xác suất

Streamlit demo

- Upload audio file
- Ghi âm từ microphone
- Hiển thị emotion label
- Hiển thị confidence và xác suất từng lớp

- Inference đọc lại `feature_type` và `n_features` từ checkpoint để tránh mismatch giữa train và predict.

Điểm mạnh

- Pipeline end-to-end rõ ràng.
- Có ablation theo feature và tuning.
- Final metrics cao và cân bằng.
- Có demo phục vụ trình bày và kiểm thử.

Hướng cải thiện

- Đánh giá thêm trên speaker-independent split.
- Kiểm thử thêm trên dữ liệu ngoài RAVDESS.
- Tăng robustness với audio thực tế, nhiễu và microphone khác nhau.

Kết quả chính

Hệ thống CNN1D với MFCC- Δ , label smoothing, dropout tuning, AdamW và augmentation nhẹ đạt **91.67%** accuracy và **91.45%** Macro F1 trên test set.

- MFCC baseline là mốc tham chiếu tốt, nhưng chưa khai thác đầy đủ thông tin động học.
- MFCC- Δ cần đi kèm regularization và optimization phù hợp.
- Confusion matrix cho thấy phần lớn lỗi nằm ở các cặp cảm xúc có biểu hiện âm học gần nhau.
- Hướng mở rộng hợp lý: actor-independent split, cross-dataset evaluation và cải thiện robustness cho audio thực tế.

Cảm ơn thầy/cô và các bạn!

Q&A